附 件 1：

是否涉密	

河海大学

专业学位硕士研究生
论文中期考核报告书

论 文 题 目 面向用户兴趣演化的联邦动态图推荐方法研究

姓 名 魏来

学 号 241607010057

专业类别领域 电子信息

培 养 类 型 ☑全日制 ☐非全日制

校 内 导 师 谢在鹏

校 外 导 师 包晨强

入 学 日 期 2024 年 9 月 5 日

报 告 日 期

报 告 地 点

研究生院制表

河海大学专业学位硕士研究生中期考核表

学　号	241607010057	学生姓名	魏来	专业类别领域	电子信息
校 内 导 师 信 息					
姓　名	谢在鹏	职称/职务	副教授	专　业	计算机科学与技术
所在学院	计算机与软件学院	联系电话	18305166195	E_mail	zaipengxie@hhu.edu.cn
通讯地址	江苏省南京市江宁区佛城西路 8 号河海大学				
校 外 导 师 信 息					
姓　名	包晨强	职称/职务	软件开发副经理	专　业	软件开发
所在单位	昆山丘钛电子科技股份有限公司	联系电话	18862489982	E_mail	1463473358@qq.com
通讯地址	江苏省昆山市古城丘钛莱斯路 89 号				

1. 开题时拟定的研究方案、进度计划；若开题时的研究方案已经调整，应说明调整的原因、调整后该领域的国内外研究状况分析、研究内容、研究方法、进度计划等。（2000 字）

一、 研究方案

1. 研究内容

联邦推荐系统（Federated Recommendation System, FRS）在原始行为数据不出端的前提下，为跨设备个性化推荐提供了有效范式。然而，在真实动态环境中，用户兴趣并非静态不变，而是会随着时间、场景和交互行为持续演化。传统联邦推荐方法通常依赖周期性参数聚合，容易将用户偏好视为相对稳定的局部表示，难以及时捕捉用户短期兴趣变化，从而造成全局模型对兴趣漂移响应滞后。与此同时，为增强客户端之间的协同能力，现有研究逐渐引入用户关系图或图神经网络结构，但动态图协同在联邦环境中也带来了新的稳定性问题：若图结构演化直接依赖客户端本地梯度更新，特征表示学习

与拓扑结构更新之间容易形成强耦合，进而引发边关系频繁震荡、局部训练不稳定和推荐性能波动；若采用静态或弱动态关系图，又难以及时适应用户兴趣关系的变化。

现有研究在处理上述问题时，往往难以同时兼顾兴趣演化的敏感性与动态图协同的稳定性。一方面，传统序列联邦推荐方法主要依赖客户端本地行为序列，能够刻画个体偏好，但受限于局部视角，难以突破客户端之间的信息隔离；静态图联邦推荐方法虽然引入了跨用户协同关系，但其拓扑结构更新滞后，对兴趣漂移和新用户接入的适应能力有限。另一方面，部分动态图或持续学习方法虽然尝试建模时变兴趣和关系演化，但大多将图结构更新与本地模型优化过程紧密绑定，缺乏对“本地特征学习”和“全局拓扑演化”之间关系的显式解耦，直接应用于部分客户端参与、异步更新和非独立同分布数据并存的联邦推荐场景时，容易产生结构震荡和跨轮性能波动。进一步地，在客户端部分参与、用户交互稀疏和兴趣持续漂移共同作用下，服务器端获得的兴趣信息往往呈现分散、异步和局部化特征，不同客户端学习到的兴趣表示可能缺乏统一的全局语义参考，导致兴趣空间碎片化，并影响低活跃用户和新客户端的兴趣对齐能力。因此，动态联邦推荐的关键不只是引入更多模型模块，而是需要围绕“兴趣如何演化建模”“动态图如何稳定演化”以及“全局兴趣语义如何对齐”建立连续的协同机制。

针对上述问题，本文拟从三个层面展开研究。其一，研究面向兴趣演化的长短期解耦个性化建模方法，区分用户近期行为所反映的短期兴趣与跨客户端协同关系所体现的长期兴趣，使模型既能够感知用户即时偏好变化，又能够利用全局协同信息缓解单客户端局部视角带来的信息孤岛问题。其二，研究基于兴趣摘要缓存的外生动态图演化与稳定控制机制，将用户关系图的更新从客户端本地梯度优化过程中解耦出来，由服务器端基于客户端上传的兴趣摘要缓存维护全局动态图，并通过平滑边权更新、时间平滑约束和结构

稳定约束降低特征表示与拓扑结构之间的相互扰动。其三，在前两项研究基础上，进一步探索原型语义记忆驱动的跨客户端兴趣对齐机制，将动态积累的客户端兴趣摘要沉淀为相对稳定的全局兴趣原型，为分散客户端兴趣表示提供统一语义锚点，从而缓解部分参与、交互稀疏和兴趣漂移导致的全局兴趣空间碎片化问题，并为低活跃用户和新客户端接入提供更稳定的语义参考。

2. 所提方法

为应对联邦推荐场景下用户兴趣动态漂移、客户端信息孤岛、动态图结构震荡以及全局兴趣语义对齐困难等问题，本文提出一种面向兴趣演化的联邦动态图推荐框架 FedDIEG（Federated Dynamic Graph Recommendation for Interest Evolution）。该框架的核心思想是：在客户端侧进行长短期解耦的个性化兴趣建模，在服务器侧基于客户端上传的兴趣摘要缓存维护外生动态图结构，并通过稳定控制机制降低本地特征学习与全局拓扑更新之间的强耦合。同时，服务器进一步维护原型语义记忆，用于为分散客户端兴趣表示提供全局语义锚点，从而实现原始行为数据不出端条件下的动态协同推荐。

如图 1 所示，FedDIEG 的整体流程围绕三个机制展开：第一，客户端侧的长短期解耦兴趣建模用于刻画用户兴趣演化；第二，服务器端的外生动态图演化与稳定控制用于维护动态跨客户端协同关系；第三，原型语义记忆用于缓解部分参与、交互稀疏和兴趣漂移导致的全局兴趣空间碎片化问题。客户端仅保留本地原始交互序列，不直接上传原始行为数据；服务器基于客户端上传的兴趣摘要及历史缓存维护全局动态用户关系图，并进一步沉淀全局兴趣原型，用于支持跨客户端兴趣对齐和新客户端接入。

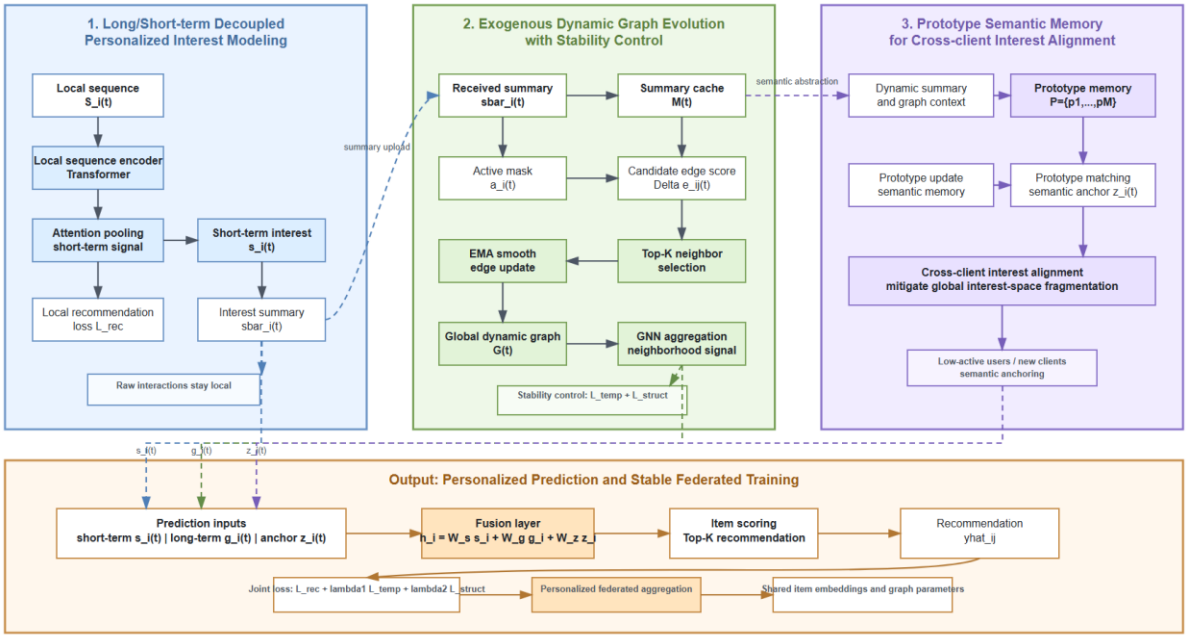


图 1 FedDIEG 模型框架图

首先，在面向兴趣演化的长短期解耦个性化建模阶段，用户交互序列$\boldsymbol{S}_i^{(t)}$被输入客户端本地序列编码器，通过自注意力机制捕捉序列内部的时间依赖关系，并经注意力池化得到短期兴趣表示$\boldsymbol{s}_i^{(t)}$。该表示主要反映用户当前阶段的即时偏好，对兴趣漂移具有较强敏感性。与此同时，客户端根据服务器下发的动态图邻居结构，聚合一阶邻居的脱敏协同信息，得到长期协同兴趣表示$\boldsymbol{g}_i^{(t)}$。短期兴趣强调个体近期变化，长期兴趣强调跨客户端协同关系，二者通过融合层得到统一用户表示：

$$\boldsymbol{h}_i^{(t)} = W_s \boldsymbol{s}_i^{(t)} + W_g \boldsymbol{g}_i^{(t)},$$

随后，模型基于$\boldsymbol{h}_i^{(t)}$与候选物品表示计算推荐得分，完成 Top-K 推荐预测。由此，FedDIEG 将“个体兴趣漂移感知”和“全局协同信息利用”统一到同一兴趣表示框架中。

其次，在外生动态图演化与稳定控制方面，FedDIEG 并不假设所有客户

端在每轮均在线，也不要求客户端在本地访问其他用户兴趣表示或计算跨用户边权。设第t轮参与训练的客户端集合为C_t，其规模为$C_t = \max(\lfloor C \cdot N \rfloor, 1)$。服务器端为每个客户端维护最新可用兴趣摘要缓存，用于支持部分参与条件下的异步图演化。对于参与客户端$i \in C_t$，客户端完成本地训练后上传当前短期兴趣摘要，服务器更新其缓存；对于非参与客户端，服务器不主动推断其当前兴趣，而是沿用上一轮最新可用摘要。

服务器基于缓存摘要计算候选边权，并用活跃节点掩码过滤尚无有效摘要的客户端：

$$a_i^t = 1\left[\left\|\underline{s_i^t}\right\|_2 > \varepsilon\right],$$

$$\Delta \mathrm{e}_{ij}^{(t)} = a_i^t \cdot a_j^t \cdot \mathrm{sim}\left(\underline{s_i^t}, \underline{s_j^t}\right),$$

随后，服务器对每个活跃节点的候选边进行 Top-K 筛选，并采用指数移动平均进行平滑更新：

$$e_{ij}^{(t+1)} = \rho e_{ij}^{(t)} + (1-\rho)\,\Delta \mathrm{e}_{ij}^{(t)},$$

其中，ρ为历史拓扑保留系数。ρ越大，图结构越倾向于保留历史关系，变化越平滑；ρ越小，图结构对当前兴趣变化响应越敏感。通过该外生更新方式，用户关系图的演化从客户端本地梯度优化过程中解耦出来，从机制上降低特征表示学习与拓扑结构更新之间的相互扰动。

再次，为进一步提升动态训练过程的稳定性，FedDIEG 在推荐主损失之外加入时间平滑约束和结构稳定约束，构成联合优化目标：

$$\mathcal{L} = \mathcal{L}_{rec} + \lambda_1 \mathcal{L}_{temp} + \lambda_2 \mathcal{L}_{struct}.$$

其中，$\mathcal{L}_{rec}$用于优化推荐预测，$\mathcal{L}_{temp}$用于限制相邻轮次兴趣表示的过度偏移，$\mathcal{L}_{struct}$用于抑制边权更新建议的剧烈波动。该设计使模型在保持兴趣漂移感知能力的同时，降低动态图联邦训练中的边关系震荡和跨轮性能波动。

最后，考虑到动态联邦推荐中客户端部分参与、用户交互稀疏和兴趣持

续漂移可能导致全局兴趣空间碎片化，FedDIEG 进一步引入原型语义记忆机制。服务器基于长期积累的客户端兴趣摘要维护全局兴趣原型，将分散、异步、动态变化的客户端兴趣表示映射到相对稳定的语义锚点上。该机制不直接替代动态图协同，而是在动态图局部邻居关系之外提供全局语义参考，用于辅助低活跃用户兴趣对齐和新客户端接入。对于新客户端，服务器可根据其初始兴趣摘要匹配相近原型，为其提供初始语义位置和候选拓扑锚点，从而缓解历史交互稀疏和初始邻居缺失问题。

综上，FedDIEG 的核心贡献体现在三个层面：通过长短期兴趣解耦解决动态偏好建模问题，通过外生动态图演化与稳定控制缓解特征学习和拓扑更新强耦合问题，并通过原型语义记忆为跨客户端兴趣表示提供全局语义锚点。上述设计使模型能够在原始行为数据不出端的条件下，同时提升兴趣漂移适应能力、动态图协同稳定性和新客户端接入能力。

3. 研究试验

（1）实验基础设定

1) 数据集：选用 MovieLens-1M 及 Amazon 旗下的 Video Games、Arts Crafts and Sewing、Digital Music 作为评测数据集。所有数据集均按照统一预处理流程构造用户交互序列，并在相同负采样策略和评价候选集下进行比较。

2) 对比基准：传统联邦推荐方法 FedMF、纯序列联邦推荐方法 FedSASRec、静态图联邦推荐方法 GPFedRec、时序抗漂移方法 FCUCR、动态图推荐方法 TarDGR、联邦持续推荐方法 F3CRec、基于扩散增强与引导去噪的联邦推荐方法。

（2）核心实验规划

1) 长短期解耦兴趣建模综合性能验证

在标准 Leave-One-Out（LOO）协议下，评估 FedDIEG 与 baselines

在 HR@10、NDCG@10 等指标上的总体推荐性能。该实验主要验证 FedDIEG 在常规联邦推荐场景下是否能够在不牺牲基础推荐精度的前提下提升排序质量。同时，设计 ShortOnly、LongOnly 和 Full Model 等内部消融配置，分析短期兴趣建模与长期协同兴趣建模的互补作用，验证长短期解耦机制对用户兴趣演化建模的有效性。

2) 外生动态图演化鲁棒性验证

采用 5 段滚动时间窗口模拟真实动态推荐环境中的兴趣漂移和时序异质性。为避免时间信息泄漏，本文按照交互时间戳进行顺序切分，模型仅在窗口W_t上训练或适配，并在后续窗口W_{t+1}上评估。所有方法使用相同的数据划分、负采样策略和评价候选集。该实验比较 FedDIEG 与各类 baseline 在 Avg Window NDCG@10、Avg Adaptation Gain 和 Avg Boundary Drop 等指标上的表现，重点验证外生动态图演化机制是否能够提升模型对兴趣漂移的适应能力。

3) 外生动态图稳定控制机制验证

复用滚动时间窗口环境进行稳定性分析和损失项消融。分别设置 Ours-Plain、Ours-NoTemp、Ours-NoStruct 和 Ours-Full 等配置，观察时间平滑约束与结构稳定约束对训练过程的影响。评价指标包括 Loss Oscillation、Avg Boundary Drop、Stability Score，以及适用于动态图方法的 Edge Change Rate（ECR）。对于不显式维护动态图边关系的 baseline，仅报告性能波动和损失震荡类指标，不强行计算 ECR。该实验用于验证 FedDIEG 是否能够缓解本地特征学习与全局拓扑演化之间的强耦合震荡。

4) 原型语义记忆驱动的跨客户端兴趣对齐验证

该实验主要验证原型语义记忆机制对跨客户端兴趣空间对齐的作用。在统一数据划分和联邦训练协议下，本文比较 FedDIEG 与各类 baselines

在不同交互稀疏程度用户上的推荐性能。具体而言，按照用户历史交互长度将测试用户划分为低、中、高交互三组，并报告 HR@10 和 NDCG@10，以评估原型语义记忆对稀疏用户兴趣表示的补偿作用。同时，在滚动时间窗口环境下比较 Avg Window NDCG@10、Avg Boundary Drop 和表示漂移幅度，分析其对动态兴趣空间稳定性的影响。

为验证该机制的独立贡献，本文设置 Ours-NoPrototype、Ours-RandomPrototype、Ours-NoProtoAlign 和 Ours-Full 四种配置，分别考察移除原型库、使用随机静态原型、去除原型对齐约束以及完整模型时的性能差异。通过对比排序指标、低交互用户性能、跨窗口表示漂移和原型分配一致性，验证原型语义记忆是否能够缓解全局兴趣空间碎片化，并提升跨客户端兴趣表示的一致性。

二、 进度计划

2025.08—2025.11：文献调研、问题分析、确定研究方向，完成开题报告。

2025.11—2026.01：设计模型结构，完成算法设计文档与初步伪代码。

2026.01—2026.03：编写实验代码，实现主模型与对照算法。

2026.03—2026.07：系统性实验验证，完成消融分析报告。

2026.07—2026.10：优化模型性能，总结实验结果，申请专利。

2026.11—2027.04：撰写并完成论文，参加答辩。

2、学位论文的研究进展情况、阶段性成果论述。（1500 字）

一、研究进展情况

目前，学位论文已基本完成从研究问题凝练、模型方法设计到主体实验验证的主要工作。围绕“面向兴趣演化的联邦动态图推荐方法研究”这一主题，本文主要聚焦动态联邦推荐中的三个关键问题：一是用户兴趣随时间持续演化，传统联邦推荐中的周期性参数聚合难以及时捕捉局部偏好变化；二是静态用户关系图难以适应兴趣漂移，而直接引入动态图更新又容易造成特

征学习与拓扑演化之间的强耦合震荡；三是在客户端部分参与、用户交互稀疏和兴趣持续漂移共同作用下，不同客户端学习到的兴趣表示可能缺乏统一语义参考，导致全局兴趣空间碎片化和跨客户端兴趣对齐困难。

针对前两个问题，本文已完成 FedDIEG 框架的主体设计与系统实验验证。首先，针对用户兴趣持续演化问题，本文提出面向兴趣演化的长短期解耦个性化建模方法，在客户端侧提取用户近期行为中的短期兴趣表示，在服务器协同侧依托动态图邻居聚合获得长期协同兴趣表示，并将二者融合用于推荐预测，从而同时刻画用户即时兴趣漂移和跨客户端协同关系。围绕该机制，本文已完成标准 LOO 协议下的综合性能实验和 ShortOnly、LongOnly、Full Model 等消融实验，验证了长短期兴趣解耦对提升推荐精度和缓解信息孤岛问题的有效性。

其次，针对动态图协同中的特征学习与拓扑演化强耦合问题，本文提出基于兴趣摘要缓存的外生动态图演化与稳定控制机制。服务器端基于客户端上传的兴趣摘要缓存异步维护全局动态图，并通过平滑边权更新、时间平滑约束和结构稳定约束降低动态图更新过程中的拓扑震荡和跨轮性能波动。围绕该机制，本文已完成滚动时间窗口下的兴趣漂移鲁棒性实验和稳定性消融实验，验证了外生动态图演化与稳定控制的有效性。

对于第三个问题，即动态联邦推荐中的全局兴趣语义参考缺失和跨客户端兴趣空间碎片化问题，本文目前已获得一定前置证据。现有的新客户端接入实验表明，在用户交互极度稀疏、初始拓扑位置缺失的场景下，原型信息能够为客户端提供初始语义锚点，并改善早期适应效果。这说明原型语义记忆机制具备缓解稀疏兴趣表示和辅助跨客户端兴趣对齐的潜力。后续工作将围绕该问题进一步开展系统实验，包括低交互用户分组性能分析、跨时间窗口表示漂移度量、原型分配一致性分析，以及 NoPrototype、RandomPrototype 和 NoProtoAlign 等消融实验，以完整验证原型语义记忆机制对全局兴趣空间

对齐的作用。

二、阶段性成果论述

实验一：长短期解耦架构的综合性能验证

该实验主要验证 FedDIEG 在标准联邦推荐场景下的整体推荐精度与结果稳定性。本文将 FedDIEG 与 FedMF、FedSASRec、GPFedRec、FCUCR、F3CRec 和 DGFedRS 等 baseline 进行对比，并在 MovieLens-1M、Amazon-Digital Music、Amazon-Video Games、Amazon-Arts Crafts and Sewing 四个数据集上报告 HR@10/Recall@10 和 NDCG@10。为降低单次随机实验带来的偶然性，本文采用多随机种子重复实验，并报告 mean ± std，同时对 FedDIEG 与各数据集上的最强 baseline 进行统计显著性检验。

如图 2 和表 1 所示，FedDIEG 在四个数据集上均取得最优的 NDCG@10 和 HR@10/Recall@10。具体来看，FedDIEG 在 MovieLens-1M、Digital Music、Video Games 和 Arts Crafts and Sewing 上的 NDCG@10 分别达到 0.4934、0.3354、0.4501 和 0.3661，相比对应最强 baseline 分别提升约 2.32%、2.69%、1.17% 和 2.21%。同时，FedDIEG 的标准差整体较小，说明其在不同随机种子下具有较稳定的性能表现。统计显著性检验进一步表明，FedDIEG 相比最强 baseline 的性能提升并非由随机波动造成，而是在四个数据集的 NDCG@10 上均达到显著性水平。

从图 2 的收敛曲线可以看出，各方法在训练前期均随联邦通信轮次增加而快速提升，随后逐渐进入稳定阶段。相比其他 baseline，FedDIEG 在中后期保持更高的 NDCG@10 收敛上界，并在四个数据集上均呈现稳定领先趋势。该结果表明，单纯依赖本地序列建模、静态图协同或一般动态图增强方法，仍难以充分兼顾用户即时兴趣变化和跨客户端协同信息；而 FedDIEG 通过长短期兴趣解耦建模，将短期兴趣感知与长期图协同结合起来，能够更有效地刻画用户兴趣演化，从而提升标准联邦推荐场景下的整体推荐精度和训

练稳定性。

表 1：不同方法在四个数据集上的总体性能对比

Dataset	Method	NDCG@10 ↑mean ± std	HR@10↑ / Recall@10 mean ± std
Movielens-1M	FedMF	0.3248 ± 0.0041	0.5717 ± 0.0031
	FedSASRec	0.4790 ± 0.0027	0.7280 ± 0.0033
	GPFedRec	0.4801 ± 0.0036	0.7284 ± 0.0032
	FCUCR	0.4592 ± 0.0050	0.7111 ± 0.0036
	F3CRec	0.4822 ± 0.0042	0.7319 ± 0.0055
	DGFedRS	0.4748 ± 0.0034	0.7174 ± 0.0042
	FedDIEG	**0.4934 ± 0.0012**	**0.7421 ± 0.0025**
Digital Music	FedMF	0.2971 ± 0.0057	0.4605 ± 0.0085
	FedSASRec	0.3257 ± 0.0051	0.5219 ± 0.0068
	GPFedRec	0.3266 ± 0.0049	0.5224 ± 0.0072
	FCUCR	0.2880 ± 0.0047	0.4768 ± 0.0079
	F3CRec	0.3265 ± 0.0046	0.5218 ± 0.0063
	DGFedRS	0.3197 ± 0.0023	0.5154 ± 0.0037
	FedDIEG	**0.3354 ± 0.0045**	**0.5283 ± 0.0061**
Video Games	FedMF	0.3836 ± 0.0028	0.5910 ± 0.0047
	FedSASRec	0.4423 ± 0.0022	0.6663 ± 0.0032
	GPFedRec	0.4449 ± 0.0013	0.6690 ± 0.0019
	FCUCR	0.4337 ± 0.0011	0.6573 ± 0.0019
	F3CRec	0.4445 ± 0.0014	0.6684 ± 0.0014
	DGFedRS	0.4355 ± 0.0025	0.6653 ± 0.0023
	FedDIEG	**0.4501 ± 0.0018**	**0.6784 ± 0.0022**
Arts Crafts and Sewing	FedMF	0.3374 ± 0.0008	0.5157 ± 0.0015
	FedSASRec	0.3572 ± 0.0011	0.5546 ± 0.0013
	GPFedRec	0.3582 ± 0.0015	0.5546 ± 0.0017
	FCUCR	0.3505 ± 0.0043	0.5517 ± 0.0044
	F3CRec	0.3581 ± 0.0011	0.5550 ± 0.0008
	DGFedRS	0.3449 ± 0.0025	0.5450 ± 0.0033
	FedDIEG	**0.3661 ± 0.0011**	**0.5616 ± 0.0010**

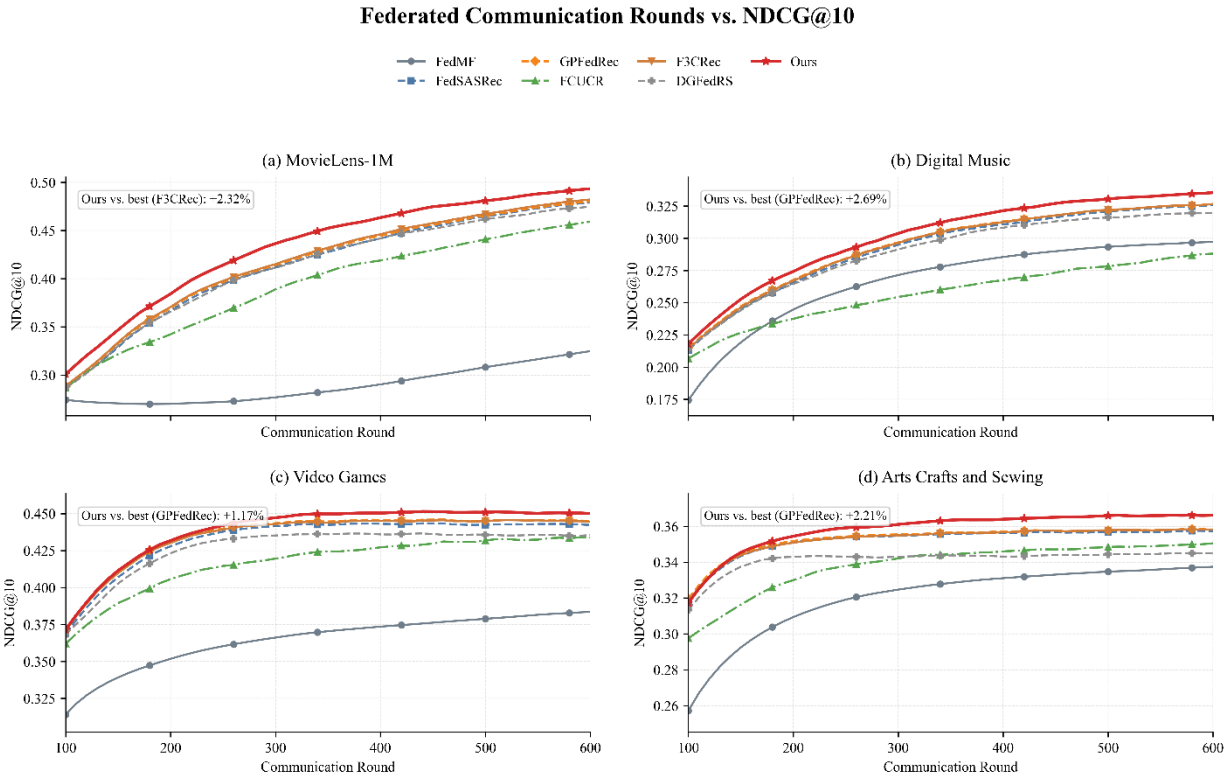


图 2 联邦通信轮次-NDCG@10 收敛曲线

实验 1 消融实验：

为了验证长短期解耦机制的有效性，我们通过移除特定模块进行了消融实验。消融结果表明，长短期兴趣分支均对 FedDIEG 的性能具有贡献。Ours-ShortOnly 在四个数据集上均明显低于完整模型，说明仅依赖短期行为难以刻画用户稳定偏好；Ours-LongOnly 优于 Ours-ShortOnly，但仍低于 Ours，表明长期兴趣虽能提供稳定表示，但不足以捕捉近期兴趣变化。完整模型 Ours 在所有数据集上均取得最优 HR@10 和 NDCG@10，说明长短期兴趣解耦与融合能够同时利用用户的稳定偏好和即时兴趣漂移，从而提升推荐准确性与排序质量。

表 2：实验 1 消融实验结果

Method	MovieLens-1M	Digital Music	Video Games	Arts Crafts and Sewing

	HR@10 ↑/ NDCG@10↑	**HR@10↑ / NDCG@10↑**	**HR@10↑ / NDCG@10↑**	**HR@10↑ / NDCG@10↑**
Ours-ShortOnly	0.6428 ± 0.0030 / 0.4182 ± 0.0016	0.4537 ± 0.0068 / 0.2764 ± 0.0050	0.5689 ± 0.0027 / 0.3716 ± 0.0021	0.4698 ± 0.0014 / 0.2987 ± 0.0015
Ours-LongOnly	0.6815 ± 0.0028 / 0.4449 ± 0.0015	0.4886 ± 0.0064 / 0.3048 ± 0.0048	0.6142 ± 0.0026 / 0.4057 ± 0.0020	0.5136 ± 0.0013 / 0.3294 ± 0.0014
Ours-Full	**0.7421 ± 0.0025 / 0.4934 ± 0.0012**	**0.5283 ± 0.0061 / 0.3354 ± 0.0045**	**0.6784 ± 0.0022 / 0.4501 ± 0.0018**	**0.5616 ± 0.0010 / 0.3661 ± 0.0011**

实验二：动态图外生演化机制的鲁棒性验证

该实验主要验证 FedDIEG 在用户兴趣随时间漂移场景下的动态适应能力与跨窗口鲁棒性。本文采用五段滚动时间窗口模拟真实推荐环境中的兴趣演化过程，按照交互时间戳顺序切分数据，模型仅利用当前窗口 W_t 中的交互进行训练或适配，并在后续时间窗口上进行评估，以避免时间信息泄漏。实验比较 FedDIEG 与 FedMF、FedSASRec、GPFedRec、FCUCR、F3CRec 和 DGFedRS 等 baseline 在 Avg Window NDCG@10、Avg Adaptation Gain 和 Avg Boundary Drop 等指标上的表现，并通过窗口级 NDCG@10 曲线观察不同方法在连续时间窗口中的性能变化趋势。

如图 3 和表 3 所示，FedDIEG 在动态时间窗口场景下整体表现出更好的窗口平均推荐性能和兴趣漂移适应能力。从 NDCG@10 曲线可以看出，FedDIEG 在四个数据集上均保持领先或最优水平，相比对应最强 baseline 分别取得约 3.54%、2.17%、1.03% 和 0.87% 的提升。尤其是在窗口持续推进时，FedDIEG 的性能曲线能够跟随新窗口中的兴趣变化持续上升或保持较高水平，说明模型能够较好地利用新增交互完成偏好更新。

这一结果与 FedDIEG 的外生动态图演化机制密切相关。在动态联邦推荐中，用户兴趣表示和图拓扑结构会相互影响：本地兴趣表示用于更新边关系，更新后的邻居结构又会影响下一轮 GNN 聚合和用户表示学习。若图结构更新直接绑定客户端本地训练过程，短期兴趣噪声、客户端部分参与造成的观测缺失以及时间窗口切换带来的分布变化，容易被放大为拓扑震荡和性

能波动。FedDIEG 通过服务器端兴趣摘要缓存维护动态图，在客户端未参与时沿用其最新可用摘要，并结合活跃节点掩码、Top-K 邻居筛选和指数平滑边权更新，使动态图既能响应兴趣漂移，又不会被单轮局部扰动剧烈改变。因此，相比本地序列模型、静态图协同方法以及一般动态增强方法，FedDIEG 能够在跨窗口迁移过程中获得更稳定的长期协同信号。

总体来看，动态推荐场景下的关键问题并非简单引入动态图，而是如何稳定地更新动态图。FedDIEG 将图结构演化从客户端本地梯度优化过程中解耦出来，通过兴趣摘要缓存和外生平滑更新降低特征学习与拓扑变化之间的强耦合，从而在保持较高窗口推荐精度的同时提升了模型对兴趣漂移和时间窗口切换的鲁棒性。

表 3：不同方法在动态时间窗口切换场景下的鲁棒性对比

Dataset	**Method**	**Avg Window NDCG@10 ↑**	**Avg Adaptation Gain ↑**	**Avg Boundary Drop ↓**
Movielens-1M	FedMF	0.2472 ± 0.0034	**0.1382** ± 0.0047	0.1215 ± 0.0053
	FedSASRec	0.4046 ± 0.0055	0.1117 ± 0.0040	0.0399 ± 0.0037
	GPFedRec	0.4078 ± 0.0050	0.1111 ± 0.0027	0.0388 ± 0.0025
	FCUCR	0.3905 ± 0.0047	0.1108 ± 0.0030	0.0438 ± 0.0040
	F3CRec	0.4079 ± 0.0048	0.1111 ± 0.0026	0.0392 ± 0.0020
	DGFedRS	0.4009 ± 0.0043	0.1088 ± 0.0046	0.0398 ± 0.0049
	FedDIEG	**0.4224** ± 0.0028	0.1154 ± 0.0028	**0.0361** ± 0.0025
Digital Music	FedMF	0.1597 ± 0.0020	0.0993 ± 0.0026	**0.0941** ± 0.0024
	FedSASRec	0.2803 ± 0.0024	0.1508 ± 0.0019	0.1168 ± 0.0027
	GPFedRec	0.2818 ± 0.0036	0.1517 ± 0.0023	0.1175 ± 0.0029
	FCUCR	0.2467 ± 0.0067	0.1417 ± 0.0055	0.1164 ± 0.0057
	F3CRec	0.2819 ± 0.0034	0.1523 ± 0.0023	0.1180 ± 0.0025
	DGFedRS	0.2780 ± 0.0016	0.1513 ± 0.0015	0.1186 ± 0.0019
	FedDIEG	**0.2880** ± 0.0011	**0.1556** ± 0.0021	0.1172 ± 0.0025
Video Games	FedMF	0.2506 ± 0.0032	0.1874 ± 0.0030	0.1872 ± 0.0035
	FedSASRec	0.4687 ± 0.0024	0.2950 ± 0.0023	0.2514 ± 0.0028
	GPFedRec	0.4699 ± 0.0028	0.2960 ± 0.0019	0.2528 ± 0.0017
	FCUCR	0.4266 ± 0.0062	0.2821 ± 0.0057	**0.2432** ± 0.0066
	F3CRec	0.4699 ± 0.0022	0.2972 ± 0.0014	0.2539 ± 0.0019
	DGFedRS	0.4627 ± 0.0030	0.2937 ± 0.0026	0.2521 ± 0.0030
	FedDIEG	**0.4748** ± 0.0023	**0.2991** ± 0.0025	0.2511 ± 0.0026
Arts Crafts and Sewing	FedMF	0.2561 ± 0.0017	**0.1460** ± 0.0016	0.1279 ± 0.0019
	FedSASRec	0.3731 ± 0.0012	0.1353 ± 0.0007	0.0776 ± 0.0010

	GPFedRec	0.3730 ± 0.0011	0.1365 ± 0.0005	0.0790 ± 0.0007
	FCUCR	0.3274 ± 0.0026	0.1363 ± 0.0015	0.0866 ± 0.0022
	F3CRec	0.3734 ± 0.0012	0.1383 ± 0.0005	0.0810 ± 0.0011
	DGFedRS	0.3606 ± 0.0019	0.1306 ± 0.0016	**0.0776** ± 0.0012
	FedDIEG	**0.3767** ± 0.0004	0.1384 ± 0.0019	0.0810 ± 0.0022

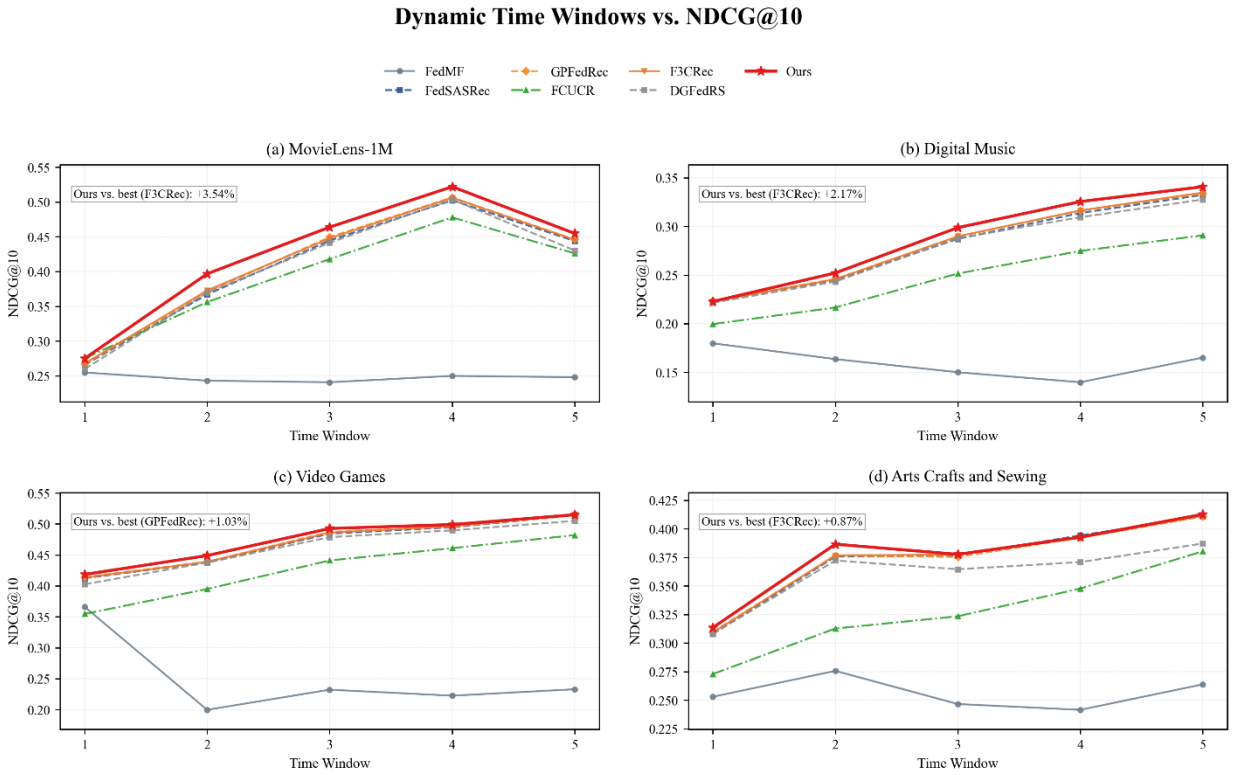


图 3 五个时间窗口下各方法 NDCG@10 变化折线图

实验 2 消融实验：

从表 4 可看出，外生动态图更新和平滑衰减机制均对 FedDIEG 的跨窗口鲁棒性具有积极作用。去除动态图更新后，Ours-StaticGraph 在四个数据集上的 Avg Window NDCG@10 和 Avg Adaptation Gain 均明显下降，同时 Avg Boundary Drop 增大，说明静态图结构难以及时适应用户兴趣关系的时间变化，窗口切换时更容易出现性能下跌。

相比之下，Ours-NoDecay 保留了动态图更新，因此整体优于 Ours-StaticGraph，但仍低于完整模型。这表明动态图更新能够增强模型对兴趣漂移的适应能力，但如果缺少平滑衰减机制，图结构仍容易受到短期兴趣噪声和窗口切换扰动影响。完整模型 Ours 在所有数据集上取得最高的 Avg

Window NDCG@10 和 Avg Adaptation Gain，并保持最低的 Avg Boundary Drop，说明外生动态图演化与平滑衰减机制能够协同提升模型的动态适应性和跨窗口稳定性。

表 4：实验 2 消融实验结果

Metric	Ours-StaticGraph	Ours-NoDecay	Ours
MovieLens-1M			
Avg Window NDCG@10↑	0.4028 ± 0.0031	0.4169 ± 0.0029	**0.4224** ± 0.0028
Avg Adaptation Gain↑	0.0896 ± 0.0033	0.1048 ± 0.0030	**0.1154** ± 0.0028
Avg Boundary Drop↓	0.0584 ± 0.0029	0.0468 ± 0.0027	**0.0361** ± 0.0025
Digital Music			
Avg Window NDCG@10↑	0.2635 ± 0.0018	0.2786 ± 0.0014	**0.2880** ± 0.0011
Avg Adaptation Gain↑	0.1194 ± 0.0028	0.1378 ± 0.0024	**0.1556** ± 0.0021
Avg Boundary Drop↓	0.1546 ± 0.0031	0.1351 ± 0.0028	**0.1172** ± 0.0025
Video Games			
Avg Window NDCG@10↑	0.4386 ± 0.0029	0.4617 ± 0.0026	**0.4748** ± 0.0023
Avg Adaptation Gain↑	0.2364 ± 0.0031	0.2679 ± 0.0028	**0.2991** ± 0.0025
Avg Boundary Drop↓	0.2826 ± 0.0032	0.2638 ± 0.0029	**0.2511** ± 0.0026
Arts Crafts and Sewing			
Avg Window NDCG@10↑	0.3235 ± 0.0012	0.3512 ± 0.0008	**0.3767** ± 0.0004
Avg Adaptation Gain↑	0.0987 ± 0.0026	0.1176 ± 0.0022	**0.1384** ± 0.0019
Avg Boundary Drop↓	0.1162 ± 0.0029	0.0978 ± 0.0025	**0.0810** ± 0.0022

实验三：多约束联合优化的系统稳定性验证

该实验主要分析时间平滑约束与结构稳定约束对动态图联邦推荐稳定性的影响。本文设置 Ours-Plain、Ours-NoTemp、Ours-NoStruct 和 Ours-Full 四种配置，并从 Avg ECR、Loss Oscillation 以及跨窗口 NDCG@10 波动三个角度进行评估。

如图 4 所示，Ours-Plain 和 Ours-NoStruct 的 Edge Change Rate 较高，说明缺少结构稳定约束时动态图边关系变化更频繁；完整模型 FedDIEG 的 Avg ECR 显著更低，表明结构稳定约束能够有效抑制拓扑剧烈波动。图 5 进一步表明，去除时间平滑约束后局部训练损失震荡更加明显，而 FedDIEG 的

损失曲线整体更平滑，说明时间平滑约束有助于缓解短期更新带来的表示扰动。从图 6 和表 5 可以看出，FedDIEG 在窗口切换时的 NDCG@10 下跌幅度更小，恢复过程更稳定，并取得最高 Stability Score。总体而言，时间平滑约束主要提升训练与性能曲线的平稳性，结构稳定约束主要降低动态图边关系的频繁变化，二者协同作用使 FedDIEG 在动态场景下具有更好的稳定性和鲁棒性。

表 5 稳定性消融结果：

Method	时间平滑约束	结构稳定约束	Avg ECR↓	Loss Oscillation↓	Stability Score↑	结论
Ours-Plain	×	×				波动较大
Movielens-1M			0.8609 ± 0.0074	0.0485 ± 0.0012	0.2607 ± 0.0064	
Digital Music			0.9204 ± 0.0027	0.0724 ± 0.0018	0.0901 ± 0.0051	
Video Games			0.9418 ± 0.0012	0.0704 ± 0.0016	0.0958 ± 0.0108	
Arts			0.9287 ± 0.0011	0.0678 ± 0.0003	0.2228 ± 0.0022	
Ours-NoTemp	×	√				表征漂移明显
Movielens-1M			0.0325 ± 0.0032	0.0472 ± 0.0012	0.3013 ± 0.0059	
Digital Music			0.0609 ± 0.0012	0.0714 ± 0.0019	0.1344 ± 0.0048	
Video Games			0.0586 ± 0.0017	0.0708 ± 0.0015	0.1456 ± 0.0107	
Arts			0.0710 ± 0.0008	0.0676 ± 0.0004	0.2629 ± 0.0015	
Ours-NoStruct	√	×				拓扑变化较大
Movielens-1M			0.5817 ± 0.0035	0.0471 ± 0.0011	0.2733 ± 0.0033	
Digital Music			0.6085 ± 0.0011	0.0719 ± 0.0019	0.1087 ± 0.0043	
Video Games			0.6654 ± 0.0064	0.0704 ± 0.0015	0.1145 ± 0.0094	
Arts			0.6137 ± 0.0041	0.0678 ± 0.0007	0.2368 ± 0.0014	
Ours-Full	√	√				稳定性最好
Movielens-1M			**0.0101 ± 0.0012**	**0.0468 ± 0.0021**	**0.3041 ± 0.0019**	
Digital Music			**0.0131 ± 0.0008**	**0.0704 ± 0.0013**	**0.1399 ± 0.0011**	
Video Games			**0.0125 ± 0.0005**	**0.0687 ± 0.0010**	**0.1568 ± 0.0089**	
Arts			**0.0129 ± 0.0004**	**0.0613 ± 0.0007**	**0.2674 ± 0.0038**	

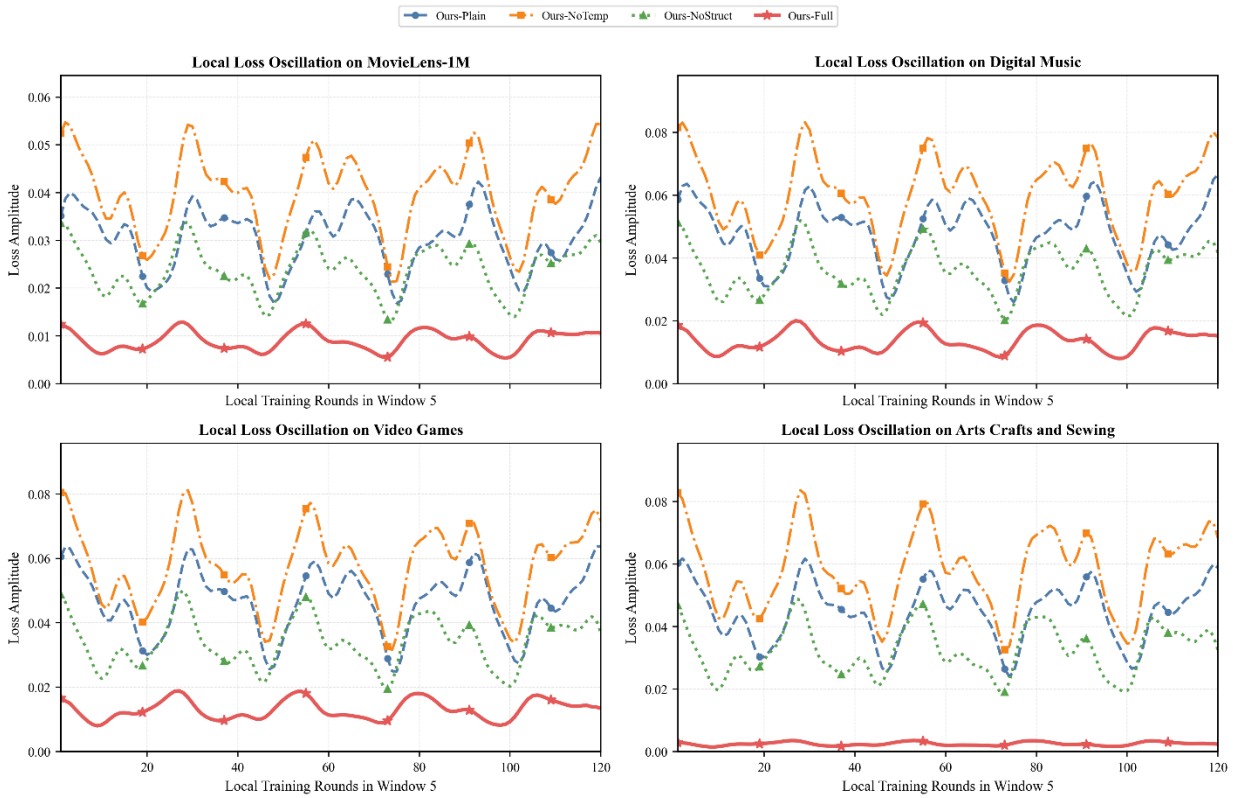


图 4 不同损失配置下局部训练损失震荡幅度图

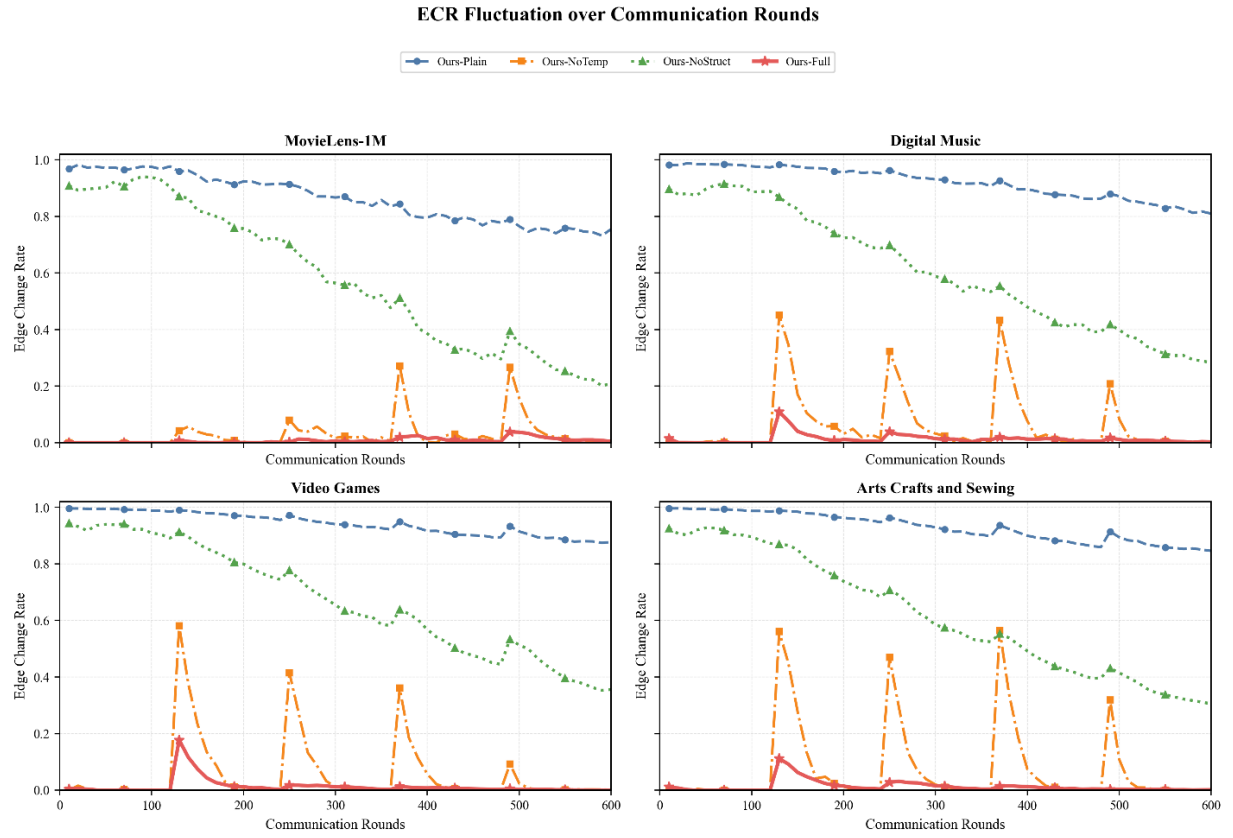


图 5 不同损失配置下 ECR 随训练轮次变化图

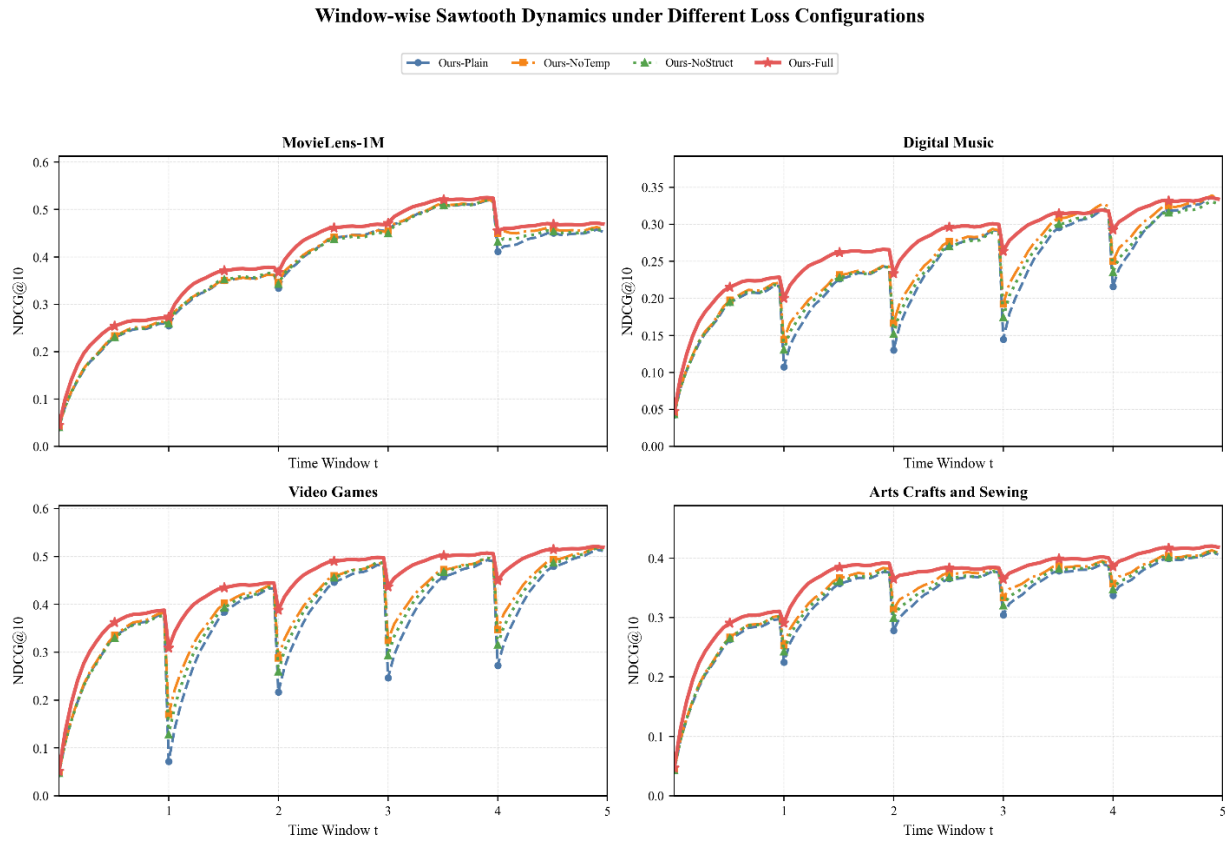


图 6 不同损失配置下 时间窗口 t vs. NDCG 锯齿状抖动图

实验四：参数敏感性分析

为进一步验证 FedDIEG 对关键超参数设置的鲁棒性，本文对模型中的四个重要参数进行敏感性分析，包括动态图邻居数量 K、边权平滑系数 ρ、时间一致性损失权重 λ_1 以及结构一致性损失权重 λ_2。其中，K 控制每个用户在动态兴趣图中聚合的邻居数量，ρ 用于调节动态图边权更新过程中的平滑程度，λ_1 和 λ_2 分别控制时间一致性约束与结构一致性约束的强度。通过分别改变上述参数并保持其他参数不变，可以评估 FedDIEG 在不同参数设置下的推荐性能和动态图稳定性，从而判断模型性能是否依赖于特定的超参数取值。

需要说明的是，本节中的 Avg. Window NDCG@10 与前文总体性能对比表中的 NDCG@10 采用不同的统计口径。总体性能对比表报告的是各方法在完整训练协议下的最终测试性能，而敏感性分析基于时间窗口漂移场景，

统计 FedDIEG 在多个时间窗口上的平均推荐性能。因此，两者的绝对数值不需要完全一致。本节更关注不同超参数取值下 Avg. Window NDCG@10、Max Drop、Avg. ECR 和 Stability 等指标的相对变化趋势，以分析关键参数对模型性能和稳定性的影响。在各个数据集上的参数敏感性分析实验结果如下表所示。

表 6 FedDIEG 在四个数据集上的参数敏感性分析数据

Dataset	Hyperparameter	Value	Avg. NDCG@10 ↑	Max Drop ↓	Avg. ECR ↓	Stability ↑
MovieLens-1M	K	5	0.4093	0.1042	0.0039	0.3048
	K	10†	0.4091	0.1075	0.0088	0.3012
	K	20	0.4091	0.1063	0.0151	0.3021
	K	40	**0.4105**	0.1091	0.0175	0.3006
	ρ	0.0	**0.4098**	0.1057	0.5722	0.2755
	ρ	0.3	0.4091	0.1046	0.0716	0.3009
	ρ	0.5	0.4093	0.1028	0.0463	0.3042
	ρ	0.8†	0.4091	0.1075	0.0088	0.3012
	ρ	0.9	0.4092	0.1031	0.0000	0.3061
	λ_1	0.0	**0.4105**	0.1082	0.0096	0.3018
	λ_1	0.005	0.4095	0.1045	0.0086	0.3046
	λ_1	0.01†	0.4091	0.1075	0.0088	0.3012
	λ_1	0.05	0.4074	0.1007	0.0159	0.3059
	λ_1	0.1	0.4072	0.1004	0.0139	0.3061
	λ_2	0.0	0.4089	0.1025	0.0115	0.3058
	λ_2	0.05	0.4090	0.1035	0.0096	0.3051
	λ_2	0.1	0.4088	0.1030	0.0095	0.3053
	λ_2	0.2†	0.4091	0.1075	0.0088	0.3012
	λ_2	0.4	**0.4094**	0.1061	0.0088	0.3028
Digital Music	K	5	0.2799	0.1376	0.0069	0.1419
	K	10†	0.2796	0.1389	0.0136	0.1401
	K	20	**0.2811**	0.1388	0.0201	0.1413
	K	40	0.2804	0.1392	0.0228	0.1400
	ρ	0.0	0.2805	0.1389	0.5979	0.1117
	ρ	0.3	0.2804	0.1385	0.1257	0.1356

	ρ	0.5	**0.2810**	0.1394	0.0804	0.1376
	ρ	0.8†	0.2796	0.1389	0.0136	0.1401
	ρ	0.9	0.2805	0.1382	0.0000	0.1423
	λ_1	0.0	**0.2818**	0.1399	0.0136	0.1412
	λ_1	0.005	0.2811	0.1404	0.0138	0.1401
	λ_1	0.01†	0.2796	0.1389	0.0136	0.1401
	λ_1	0.05	0.2803	0.1453	0.0157	0.1341
	λ_1	0.1	0.2804	0.1432	0.0158	0.1364
	λ_2	0.0	**0.2810**	0.1376	0.0139	0.1427
	λ_2	0.05	0.2806	0.1391	0.0146	0.1408
	λ_2	0.1	0.2802	0.1409	0.0147	0.1386
	λ_2	0.2†	0.2796	0.1389	0.0136	0.1401
	λ_2	0.4	0.2805	0.1390	0.0131	0.1409
Video Games	K	5	0.4618	0.3018	0.0050	0.1597
	K	10†	0.4610	0.3036	0.0127	0.1568
	K	20	0.4632	0.3042	0.0174	0.1581
	K	40	**0.4636**	0.3026	0.0237	0.1598
	ρ	0.0	0.4635	0.3038	0.6508	0.1272
	ρ	0.3	0.4642	0.3040	0.1190	0.1543
	ρ	0.5	**0.4648**	0.3103	0.0774	0.1507
	ρ	0.8†	0.4610	0.3036	0.0127	0.1568
	ρ	0.9	0.4627	0.3047	0.0000	0.1581
	λ_1	0.0	0.4635	0.3043	0.0127	0.1585
	λ_1	0.005	**0.4638**	0.3014	0.0129	0.1618
	λ_1	0.01†	0.4610	0.3036	0.0127	0.1568
	λ_1	0.05	0.4632	0.3057	0.0123	0.1570
	λ_1	0.1	0.4597	0.2956	0.0139	0.1634
	λ_2	0.0	0.4616	0.3047	0.0135	0.1562
	λ_2	0.05	0.4630	0.3042	0.0130	0.1581
	λ_2	0.1	**0.4638**	0.3064	0.0131	0.1567
	λ_2	0.2†	0.4610	0.3036	0.0127	0.1568
	λ_2	0.4	0.4622	0.3039	0.0118	0.1577
Arts Crafts and Sewing	K	5	0.3692	0.1028	0.0055	0.2661
	K	10†	0.3700	0.1019	0.0129	0.2675
	K	20	**0.3710**	0.1029	0.0193	0.2672
	K	40	0.3706	0.1029	0.0257	0.2664
	ρ	0.0	0.3710	0.1020	0.6055	0.2387

	ρ	0.3	0.3716	0.1038	0.1259	0.2616
	ρ	0.5	0.3714	0.1050	0.0813	0.2623
	ρ	0.8†	0.3700	0.1019	0.0129	0.2675
	ρ	0.9	**0.3720**	0.1045	0.0000	0.2675
	λ_1	0.0	0.3693	0.1016	0.0131	0.2670
	λ_1	0.005	0.3703	0.1030	0.0125	0.2666
	λ_1	0.01†	0.3700	0.1019	0.0129	0.2675
	λ_1	0.05	0.3713	0.1013	0.0126	0.2694
	λ_1	0.1	**0.3722**	0.1012	0.0130	0.2704
	λ_2	0.0	**0.3715**	0.1043	0.0125	0.2666
	λ_2	0.05	0.3705	0.1024	0.0130	0.2675
	λ_2	0.1	0.3709	0.1043	0.0124	0.2659
	λ_2	0.2†	0.3700	0.1019	0.0129	0.2675
	λ_2	0.4	0.3705	0.1012	0.0119	0.2688

注：† 表示主实验中采用的默认设置。Avg. NDCG@10 和 Stability 越高越好，Max Drop 和 Avg. ECR 越低越好。表中仅对每组超参数下最高的 Avg. NDCG@10 加粗。

从四个数据集的结果来看，FedDIEG 对关键超参数整体表现出较好的鲁棒性。在各个数据集中，Avg. NDCG@10 都只在较小范围内波动，没有出现由于参数变化导致性能大幅下降的情况。这说明 FedDIEG 的性能并不依赖某一个精确的超参数组合，默认设置能够在不同数据集上取得接近最优的表现。

对于邻居数量 K，不同数据集上的最优取值略有差异。例如，Video Games 上 K=40 表现最好，而 Digital Music 和 Arts 上 K=20 更优。整体趋势表明，适当增加邻居数量有助于引入更丰富的协同兴趣信息，但过大的 K 会提升 Avg. ECR，使动态图结构变化更加活跃。因此，K 主要影响模型对邻居信息的利用程度和动态图变化强度，默认值 K=10 虽不总是最优，但与最优结果差距较小，具有较好的稳定性。

边权平滑系数 ρ 对动态图稳定性的影响最为显著。在四个数据集上，随着 ρ 增大，Avg. ECR 均明显下降；当 ρ=0 时，动态图边变化率最高，稳定性得分通常最低，而当 ρ=0.8 或 ρ=0.9 时，动态图变化被显著抑制。这说明

EMA 边权平滑机制能够有效缓解动态图结构的剧烈波动。虽然 $\rho=0.9$ 在部分数据集上带来更高稳定性，但过高的平滑系数可能导致图结构更新过慢。因此，默认设置 $\rho=0.8$ 是推荐准确性和动态图稳定性之间较合理的折中。

对于时间一致性损失权重 λ_1，其影响主要体现为对时间窗口间兴趣漂移的调节。不同数据集上的最优取值并不完全一致：Video Games 在较小权重 $\lambda_1=0.005$ 下表现更好，Arts 在较大权重 $\lambda_1=0.1$ 下表现更优，而 MovieLens-1M 和 Digital Music 上整体波动较小。这表明时间一致性约束的最优强度与数据集动态特征有关。总体上，适度的 λ_1 有助于提升时间稳定性，但过强的约束可能限制模型对新兴趣分布的适应能力。

对于结构一致性损失权重 λ_2，四个数据集上的性能变化整体较小，说明 FedDIEG 对该参数不敏感。不同取值下的 Avg. NDCG@10 差异有限，默认值 $\lambda_2=0.2$ 在多数情况下接近最优。该结果表明，结构一致性约束能够作为辅助机制稳定用户表示，但模型的整体性能并不依赖于某个特定的 λ_2 取值，进一步验证了 FedDIEG 在结构正则化设置上的鲁棒性。

综上，本实验说明 FedDIEG 在关键超参数变化下具有良好的稳定性和鲁棒性。四个参数中，ρ 对动态图稳定性影响最明显，K 主要影响邻居信息利用和图结构活跃程度，λ_1 调节时间一致性与兴趣适应之间的平衡，λ_2 的影响相对温和。整体结果表明，FedDIEG 的性能提升并非依赖精细调参，而是来源于动态图建模、边权平滑以及一致性约束等机制的协同作用。

实验五：原型语义锚定机制在新客户端接入场景下的前置验证

该实验作为后续“原型语义锚定机制”的前置实验。本文认为，在动态联邦推荐中，客户端部分参与、用户交互稀疏和兴趣持续漂移会使服务器端获得的兴趣摘要呈现分散、异步和局部化特征。即使外生动态图能够缓解局部拓扑震荡，动态图边关系仍主要刻画客户端之间的局部相似性，难以提供稳定的全局兴趣语义参考。在这种情况下，低交互用户和新客户端更容易出

现兴趣表示不足、语义对齐困难和拓扑接入滞后等问题。

因此，选取新客户端接入作为原型语义锚定机制的典型前置验证场景。实验在联邦训练中途注入 25%的新客户端，并限制其初始可见交互规模，使其同时面临本地行为稀疏和动态图邻居缺失的问题。服务器端利用已有客户端兴趣摘要构建全局兴趣原型，为新客户端提供初始语义参照和图结构锚定位置，从而验证原型是否能够在缺乏充分历史交互的条件下辅助客户端快速对齐到全局兴趣空间。实验结果如下：

表 7：不同方法当新客户端接入时的平均起始 NDCG、AUC NDCG@10 统计

Method	**Initial NDCG@10**	**AUC NDCG@10**
FedMF	0.0876	0.1213
FedSASRec	0.2392	0.2474
GPFedRec	0.2400	0.2494
FCUCR	0.2366	0.2489
F3CRec	0.2397	0.2493
DGFedRS	0.2388	0.2472
FedDIEG	**0.2513**	**0.2604**

表 8：实验 5 消融实验结果

Metric	Ours-NoPrototype	Ours-NoGraphAnchor	Ours
Initial NDCG@10	0.2397	0.2412	**0.2513**
AUC NDCG@10	0.2443	0.2518	**0.2604**

实验结果表明，引入原型辅助后，FedDIEG 在新客户端接入后的早期 NDCG、AUC NDCG 和适应稳定性方面均优于或接近最优基线，说明全局兴趣原型能够为新客户端提供有效的语义锚点，缓解冷启动阶段兴趣表示不足和拓扑接入滞后的问题。该结果初步验证了原型语义锚定机制的可行性，也为后续进一步研究动态联邦推荐中的全局兴趣空间对齐问题提供了实验依据。

3、后续工作的设想、论文的主要创新点、可能遇到的困难和问题及解决方案。（500 字）

后续工作将重点围绕“原型语义记忆驱动的跨客户端兴趣对齐机制”展

开。前期实验中，新客户端接入场景已经初步表明，在用户历史交互稀疏、初始拓扑位置不足的情况下，原型信息能够为客户端提供一定的语义锚定作用。基于这一前置证据，后续将进一步将原型机制从新客户端接入场景扩展到一般动态联邦推荐过程，重点解决客户端部分参与、交互稀疏和兴趣持续漂移导致的全局兴趣空间碎片化问题。

具体而言，后续拟在服务器端维护原型语义记忆库，将不同轮次、不同客户端上传的兴趣摘要以及动态图协同信息沉淀为若干稳定的全局兴趣原型。与动态图主要刻画局部边级协同关系不同，原型语义记忆用于提供全局兴趣语义参考系，使分散客户端学习到的兴趣表示能够对齐到相对稳定的语义锚点上。该机制将作为论文后续重点创新点：一方面用于增强低交互用户的兴趣表示，缓解本地交互不足导致的语义表达不稳定；另一方面用于提升跨时间窗口下兴趣表示的一致性，降低兴趣漂移造成的全局表示空间碎片化；同时也可为新客户端接入提供更稳定的初始语义位置。

后续实验将从三个方面展开验证：首先，按照用户历史交互长度划分低、中、高交互用户组，比较有无原型语义记忆时不同用户组的 HR@10 和 NDCG@10，分析其对稀疏用户的补偿作用；其次，在滚动时间窗口环境下评估表示漂移幅度、Avg Boundary Drop 和原型分配一致性，验证其对动态兴趣空间稳定性的影响；最后，设置 NoPrototype、RandomPrototype、NoProtoAlign 和 Full Model 等消融配置，分别验证原型库、原型更新和语义对齐约束的独立贡献。

可能遇到的困难包括：原型更新可能受到稀疏用户噪声影响，原型数量和匹配范围难以确定，过强的原型对齐可能削弱个性化表达。针对这些问题，后续将采用动量更新、置信度过滤、Top-K 原型匹配、对齐损失权重调节和参数敏感性实验，寻找全局语义对齐与个性化推荐能力之间的平衡。

校内导师签字：　　校外导师签字： 

年　　月　　日　　2026 年 6 月 27 日

		姓名	职称	学科专业	所在单位	签字
评议专家组	组长	唐斌	教授	分布式计算	河海大学	
	成员	谢在鹏	副教授	分布式计算系统	河海大学	
		胡世红	讲师	边缘计算	河海大学	

专家组评审意见（对学位论文工作及中期报告撰写情况、实践情况及计划、学生的学习和工作态度等进行考查，给出考核结果和具体改进意见和建议）

1）是否通过：☐ 通过　　☐ 不通过

2）关于中期报告撰写质量及学位论文工作的具体意见（可加页）：

组长签字：

年　　月　　日